

## Abstract

Esta fue la 4ª clase del tema 2 del máster, correspondiente a la penúltima sesión de introducción al machine learning y deep learning. EBIS dirigió una clase teórica compleja sobre procesamiento del lenguaje natural (NLP), centrándose en la conexión entre deep learning y LLMs. La clase cubrió conceptos fundamentales como tokenización, embeddings y la atención en los modelos de transformadores, explicando cómo los LLMs procesan texto mediante la conversión de palabras en tokens, luego en vectores de alta dimensión, y finalmente cómo la atención permite al modelo prestar atención selectiva a palabras relevantes dentro del contexto completo de la oración. EBIS demostró estos conceptos usando un notebook con TikTok y realizó comparaciones entre español e inglés en términos de costos de tokens, explicando por qué el inglés es más eficiente en términos de procesamiento. Los estudiantes plantearon varias preguntas sobre cómo funcionan específicamente los tokens y los embeddings, y EBIS proporcionó explicaciones detalladas sobre la arquitectura subyacente de los modelos de transformadores, incluyendo las matrices Q, K y V, así como las múltiples capas de atención que permiten a los LLMs entender el contexto completo del texto de forma paralela.

## Resumen general

### Clase NLP Teórica EBIS

EBIS dirigió la clase sobre procesamiento del lenguaje natural (NLP) como parte del tema 2 del máster, señalando que es una de las clases más difíciles pero también interesantes del curso. Explicó que la clase cubriría conceptos teóricos como tokenización, medings, modelos secuenciales (RNN, LSTM) y transformers, con una demo en vivo usando un notebook. EBIS indicó que la próxima clase del miércoles se enfocaría más en la implementación y código práctico, mientras

que esta sesión serviría como un broche teórico al material visto hasta ahora.

### Procesamiento de Lenguaje Natural NLP

EBIS explicó qué es el procesamiento de lenguaje natural (NLP), definiéndolo como la rama de la inteligencia artificial que estudia cómo las máquinas pueden entender, generar y manipular el lenguaje humano en forma de texto o voz. Describió tres familias de tareas principales del NLP: comprensión, generación y conversión, y explicó que

Google ha sido el mayor proveedor de investigación y financiación en este campo durante décadas. EBIS también abordó por qué el lenguaje humano es difícil para las máquinas, destacando la ambigüedad, la necesidad de contexto y la variabilidad en el lenguaje humano como desafíos técnicos significativos.

### Proceso de Tokenización de Texto

EBIS explicó el proceso de tokenización para convertir texto en números, comparándolo con cómo se procesan las imágenes a través de convoluciones. Explicó que los tokens son unidades menores que palabras que se aprenden específicamente para cada modelo, y que se pueden dividir o combinar según su complejidad y entidad. Describió las limitaciones del one hot encoding y la alternativa de Vago Words como métodos para codificar texto numéricamente, señalando que estos métodos presentan desafíos computacionales debido a la alta dimensionalidad del diccionario de palabras.

### Tokenización en Procesamiento de Lenguaje

EBIS explicó la diferencia entre métodos tradicionales de codificación de texto como one hot encoding y la tokenización moderna utilizada en modelos de procesamiento del lenguaje natural. Explicó que la tokenización divide palabras en fragmentos significativos en lugar de usar palabras enteras, creando un vocabulario fijo de tokens que varía según el modelo (por ejemplo, GPT-4 tiene 100,000 tokens vs 50,000 en GPT-3). Los participantes PauGorritz, Mario y Mikel askaron preguntas sobre cómo se

determinan los tokens óptimos y si el mismo conjunto de tokens se utiliza consistentemente, a lo que EBIS respondió que depende del modelo específico y que el proceso se basa en pruebas y error, similar a la configuración de hiperparámetros en una convolución.

### Costos de Tokens en IA

El grupo discutió cómo el costo de tokens en modelos de IA varía según el idioma y la complejidad del modelo. EBIS explicó que las conversaciones en inglés consumen más tokens que las en español porque el procesamiento de razonamiento se realiza en inglés por optimización de tokens, y mostró ejemplos prácticos comparando la tokenización en español e inglés. Carlos preguntó sobre la rentabilidad de las empresas de IA, y EBIS respondió que actualmente no son rentables debido a los altos costos de infraestructura necesarios para manejar millones de usuarios, aunque las suscripciones básicas cuestan aproximadamente 20 euros mensuales. Moises compartió un enlace a un tokenizador online de OpenAI para visualizar la separación de tokens en tiempo real.

### Conceptos de Embeddings y Autocalización

Ruben explicó conceptos de autocalización y embeddings, definiendo embeddings como la representación de tokens como vectores en dimensiones altas (como 4,096 dimensiones) para capturar similitudes semánticas. Explicó que los embeddings se aprenden a través de redes neuronales y permiten operar con significado a nivel

vectorial, como demostró con ejemplos de operaciones lineales entre vectores. Describió cómo los modelos de lenguaje modernos utilizan embeddings para prestar atención selectiva a palabras importantes dentro de una secuencia, en lugar de procesarlas de forma secuencial tradicional.

### Capas de Atención en Lenguaje

EBIS explicó el funcionamiento de las capas de atención en los modelos de lenguaje, utilizando un ejemplo con la frase "la criatura azul y peluda andaba por el bosque verde". Demostró cómo las palabras se modifican mutuamente a través de matrices Q, K y V, donde cada token se afecta por otros tokens según su relevancia semántica. EBIS explicó que los modelos modernos como GPT-4 tienen múltiples capas de atención (aproximadamente 96 en GPT-3), cada una aprendiendo relaciones diferentes como atributos, sintaxis, prosa o información subyacente, lo que hace que sean computacionalmente muy complejos debido a las matrices gigantes de parámetros que requieren entrenar.

### Funcionamiento de Tokens en LLM

EBIS explicó a JesusdeDiego y Ruben cómo funcionan los tokens en el modelo LLM, aclarando que se refieren a palabras divididas en tokens para procesamiento por capas de atención. Explicó que cada token tiene matrices con múltiples dimensiones que generan K (significado), Q (metadatos) y V (aplicabilidad/transformabilidad), y que el modelo procesa todo el texto simultáneamente para entender las relaciones entre palabras. EBIS enfatizó que

aunque los ejemplos didácticos son útiles para comprender el concepto, la realidad del procesamiento del LLM es mucho más abstracta y compleja, ya que las matrices contienen miles de cálculos que no son fácilmente interpretables por humanos.

### Arquitectura de Modelos Transformadores

EBIS explicó la arquitectura de los modelos de transformadores, incluyendo las capas de atención y las redes neuronales, y demostró cómo funcionan los encoders y decoders en modelos como GPT. El grupo realizó ejercicios prácticos con embeddings de frases y palabras, aplicando operaciones vectoriales como sumar y restar palabras para predecir resultados. EBIS programó una sesión para el miércoles donde entrenarán un modelo LLM y revisarán el código en directo.